



TRABAJO FIN DE GRADO
INGENIERÍA INFORMÁTICA

Estimación de la calidad de imágenes médicas 3D

Aprendizaje automático y Aprendizaje profundo

Autor

Brian Sena Simons

Directores

Pablo Mesejo Santiago

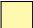









Enrique Bermejo Nievas



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

—
Granada, mes de 201

Anotaciones y Cambios

	Cambios: Desplazar sección y eliminar texto introducción	9
	Propuesta: Respuesta a Enrique, Párrafo de Aplicaciones IQA . . .	10
	Propuesta: Respuesta a Enrique, Párrafo de propósito de TFG . .	11
	Cambios: Enlazar frase motivación a continuación de segmentaciones	11
	Propuesta: Respuesta a Enrique, :nlazar con la reconstrucción de modelos y regiones anatómicas	11
	Cambios: Revisar Frase final de apartado objetivos	12
	Cambios: En respuesta a Enrique, cambios de todos los objetivos .	13
	Cambios: En respuesta a Enrique, se cambia esta sección a Funda- mentos	17
	Propuesta: Hablar de las limitaciones de métricas de distancias . .	17
	Propuesta: Enfatizar las diferencias en dificultad	18

Índice general

1. Introducción	9
1.1. Definición del Problema	9
1.2. Motivación	11
1.3. Objetivos	13
1.4. Planificación del proyecto	13
2. Fundamentos Teóricos	17
2.0.1. Subproblemas de la IQA	17
2.1. Aprendizaje Automático	19
2.2. Aprendizaje Profundo	20
2.2.1. Redes Convolucionales	22
2.2.2. Aplicadas a Videos	22
2.3. Ensemble o Conjunto <i>Deep Learning</i>	22
2.4. Imágenes médicas, Métricas y Distorsiones	22
3. Estado del Arte	23
4. Materiales, Métodos y Distorsiones	25
4.1. Materiales	25
4.2. Métodos	25
4.3. Distorsiones	25
5. Implementación y Experimentos	27
5.1. Detalles Técnicos de Implementación	27
5.2. Experimentos	27
6. Conclusiones y Trabajos Futuros	29
Bibliografía	34

Índice de figuras

1.1.	Ejemplo de visualización de un directorio <i>DICOM</i> . Se pueden observar las proyecciones axial, coronal y sagital. Además de una renderización volumétrica de los huesos. Para ello se ha utilizado <i>Slicer3D</i> [1]	12
2.1.	En este ejemplo, extraído de [2], vemos que sumar una constante positiva a una imagen de referencia (a) produce la imagen (b) que contiene la misma distancia <i>Minkowski</i> que (c), imagen fabricada por la misma constante pero permutando signo de forma aleatoria. Siendo que la percepción final es que la imagen (c) es peor que la (b).	19
2.2.	En este ejemplo, extraído de [3], la misma imagen distorsionada de distintas maneras resulta en el mismo valor $MSE=181$. Siendo evidente que algunas distorsiones producen efectos visuales más marcados que otras haciendo que no sea una buena estimación perceptual de la calidad.	20
2.3.	Ejemplo de aprendizaje supervisado y no supervisado. En el primer par, vemos como dado un conjunto de clases etiquetadas aprendemos un hiper plano que las separa. En el segundo, dado un conjunto de puntos aprendemos un conjunto de clases.	21

Índice de tablas

1.1. Planificación temporal inicial del proyecto	14
1.2. Planificación resultante del proyecto	14
1.3. Total de horas y días trabajados	15
1.4. Estimación final de coste del proyecto	15

Capítulo 1

Introducción

1.1. Definición del Problema

Con la demanda incremental de aplicaciones, tanto para el entretenimiento como para el estudio biomédico, la información visual cada vez tiene un rol más importante. Sin embargo, la calidad de la información puede sufrir drásticamente con las etapas de adquisición, procesado, compresión, transmisión y reproducción. Es por ello que poder evaluar la calidad de la información se ha vuelto un tema cada vez más importante [4].

La rama sobre la cuál nos centraremos es la evaluación de la calidad de la imagen, en inglés *Image Quality assessment (IQA)*. Es un problema fundamental en el procesamiento de imágenes y de visión por computador. Se refiere a la tarea de medir y cuantificar la calidad perceptual de una imagen, teniendo en cuenta factores como el contenido, la resolución, el contraste, las distorsiones visuales y la percepción humana. La mejora de las técnicas suele estar altamente conectado con el avance de los estudio del sistema de visión humano (*Human Vision System, HVS*) [3].

El problema de la evaluación de la calidad de la imagen se aborda mediante enfoques subjetivos y objetivos. Los enfoques subjetivos implican realizar experimentos perceptuales en los que se recopilan las opiniones y evaluaciones de los observadores humanos. Estos observadores pueden calificar las imágenes en términos de su calidad visual o realizar comparaciones entre diferentes versiones de una misma imagen. Con base a las respuestas recopiladas, se pueden establecer modelos y métricas que reflejen la calidad percibida por los humanos, también conocida como *mean opinion score, MOS*¹.

Alternativamente, los enfoques objetivos buscan desarrollar algoritmos y métricas automáticas que puedan estimar la calidad de la imagen sin intervención humana. Estos enfoques se basan en características y propiedades visuales extraídas de la imagen, que se utilizan para calcular una puntuación

Desplazamos la sección, eliminando texto de introducción

de calidad. Estas características pueden incluir medidas de nitidez, contraste, estructura, color, distribución de texturas y otros aspectos relevantes para la percepción visual.

La elección entre enfoques subjetivos u objetivos depende del contexto y los recursos disponibles. Los enfoques subjetivos son considerados como la referencia estándar para la evaluación de la calidad de la imagen, ya que capturan la apreciación humana. Sin embargo, estos enfoques pueden ser costosos y requieren de un número significativo de participantes. Mientras que los enfoques objetivos se pueden llegar a automatizar, haciendo que sea muy prácticos para grandes cantidades de datos y diversas aplicaciones.

No obstante, el objetivo es desarrollar algoritmos y métricas que puedan proporcionar una estimación precisa y consistente de la calidad de la imagen, teniendo en cuenta tanto aspectos subjetivos como objetivos respecto a las distorsiones. Y, de esta forma, poder evaluar y comparar diferentes métodos de adquisición, compresión, restauración o manipulación de imágenes teniendo en cuenta que el receptor final es el humano.

Para abordar el problema de la IQA, se emplean diversas técnicas y enfoques. Entre ellos se incluyen métodos basados en características, modelos de percepción visual, aprendizaje automático y técnicas de procesamiento de señales

Uno de los enfoques comunes es utilizar características básicas de la imagen. Las características elementales de la imagen son por ejemplo el contraste, la nitidez, la exposición y la uniformidad del color [3]. Estas características pueden ser cuantificadas mediante algoritmos de procesamiento de imágenes y proporcionar una estimación inicial de la calidad.

Por otro lado, los modelos de percepción visual intentan simular cómo el sistema visual humano percibe y evalúa la calidad de la imagen. Estos modelos se basan en el entendimiento de los mecanismos y procesos perceptuales del cerebro humano, y utilizan características visuales y estadísticas para calcular la calidad percibida [2, 5]. Buscan emular la forma en que los humanos interpretan y responden a las imágenes en términos de su calidad visual [6, 7].

Habitualmente, se suelen emplear algoritmos de aprendizaje automático para tratar de resolver el problema. Se utilizan técnicas supervisadas o no supervisadas para intentar aproximar una función que a partir del conjunto de características extraídas pueda determinar la calidad de la imagen en una escala específica, generalmente en el rango de 0 a 10.

Las aplicaciones comunes de los algoritmos de estimación de calidad suele ser la comparativa entre algoritmos de compresión, ya que permite elegir aquellos con menor pérdida de información, la generación de mapas de calidad², permitiendo el estudio de métodos de reducción de ruido, la determinación de la calidad del servicio de transmisión o *quality-of-service* (*QoS*), ya que permiten evaluar los errores de transmisión [8, 9]. Se podría incluso extender al pre-procesamiento de datos de entrenamiento o estimar la precisión de un modelo de predicción basado en la calidad de los datos [10].

El uso de algoritmos IQA se encuentra ampliamente difundido en el ámbito de las imágenes 2D, especialmente en el contexto general, con algunos métodos siendo incorporados en el ámbito médico. Lamentablemente, la naturaleza de las imágenes médicas 2D y las distorsiones que pueden presentar implican una disminución en la precisión de los modelos cuando se aplican directamente sobre ellas [4]. A parte, el número de métodos decrece al desplazarnos a tres dimensiones debido al aumento de complejidad, con ninguno, al momento de escritura, aplicado a imágenes médicas 3D. Es por ello que se propone investigar el uso de métodos tridimensionales para el ámbito biomédico, aplicado a las reconstrucciones y visualizaciones volumétricas que se suelen utilizar en medicina.

1.2. Motivación

En el caso del ámbito biomédico, dado los rápidos avances en las últimas década de las técnicas no invasivas de imágenes y la gran cantidad de fabricantes de equipamientos, nació el estándar *DICOM* [11] en 1995 con objetivo de hacer que el intercambio de imágenes médicas se realice de forma fácil, segura y con alta calidad. Permitiendo integración con diversos sistemas e incluso almacenar información extra en forma de metadatos y anotaciones, así como segmentaciones que permiten la reconstrucción 3D de diferentes regiones anatómicas.

Y, en medicina, se utilizan volúmenes tridimensionales, como tomografías computarizadas (TC) o resonancias magnéticas (RM) en lugar de radiografías convencionales, porque proporcionan una visión más completa y detallada de la anatomía y las estructuras internas del cuerpo, ver (1.1). Esto brinda a los médicos una comprensión más completa de la anatomía, les ayuda a identificar con mayor precisión lesiones, enfermedades o anomalías y a la planificación quirúrgica y otros [12–14].

Enlazar frase:
Añadido posterior a
'segmentaciones'

¹ *Mean Opinion Score* o Valor medio de opinión, consiste en la media de la opinión de diversas personas para establecer un valor de referencia.




Figura 1.1: Ejemplo de visualización de un directorio *DICOM*. Se pueden observar las proyecciones axial, coronal y sagital. Además de una renderización volumétrica de los huesos. Para ello se ha utilizado *Slicer3D* [1]

A pesar de ello, las distorsiones, que son una ocurrencia común en las imágenes cotidianas, están muy presentes en las imágenes médicas [15]. Prevalecen las distorsiones de contraste, ruido y difuminado³, que se detallarán en la sección 2.4. Estas a su vez, podrían afectar al volumen 3D que se puede generar a partir las imágenes médicas.

En [16] se estudió las razones por las que se suelen rechazar las radiografías, la relación con la calidad de la imagen y el valor del diagnóstico final. Reveló que la mayoría de los rechazos se producen por errores de posicionamiento, valores inadecuados de exposición, artefactos y los problemas de cooperación del paciente. Además, no es difícil imaginar que una alta calidad de imagen médica tiene implicaciones significativas sobre el cuidado del paciente. Ya que la mala calidad de imagen puede provocar diagnósticos erróneos o falsos negativos. Sin mencionar los elevados costes que supone realizar nuevas pruebas para conciliar las anteriores.

Resolver este problema, o dar pasos hacia adelante, formulando una medida de calidad puede conllevar a la mejora de los dispositivos médicos, de los algoritmos de comprensión, almacenado y transmisión de información (tanto a nivel médico como a cualquier aplicación con datos tridimensionales). Resultando en reducción de costes (menos pruebas), de tiempo de consultas y mejorando la calidad del diagnóstico médico.

Revisado de frase:
Reescrito el párrafo

³Con ruido nos referimos a pequeñas fluctuaciones no deseadas en los colores de los píxeles debido a interferencias de todo tipo. Difuminado se refiere a la pérdida de detalles en los bordes, como una pérdida de enfoque.

1.3. Objetivos

Para el desarrollo de este documento se plantean una serie de objetivos. El objetivo principal consiste en encontrar un método adecuado para abordar al problema de la estimación de la calidad de imágenes médicas tridimensionales. Este objetivo se puede descomponer en una serie de metas parciales:

Se generaliza los objetivos

1. Realizar una revisión del estado del arte para la estimación de calidad de imágenes $3D$, así como de la calidad de imágenes médicas en particular.
2. Estudiar las distorsiones comunes en el ámbito de la imagen. Analizar los patrones de distorsión que afectan la calidad de las imágenes biomédicas.
3. Analizar los enfoques más prometedores que permitan abordar el problema planteado.
4. Generar un conjunto de datos sintético que permita validar los métodos analizados. Para ello, será necesario estudiar diferentes estrategias y métricas de evaluación objetivas [17–19].
5. Realizar un estudio experimental que permita validar los enfoques propuestos y extraer conclusiones sobre su aplicabilidad al problema.

1.4. Planificación del proyecto

Al planificar el proyecto, es fundamental tener en cuenta que la asignatura del Trabajo Fin de Grado (TFG) tiene una carga de 12 créditos ECTS, donde cada crédito representa aproximadamente 25 horas de trabajo. En total, se estima que se necesitarán alrededor de 300 horas para llevar a cabo el proyecto. Considerando que el segundo cuatrimestre tiene aproximadamente 20 semanas, se requerirá dedicar al TFG unas 15 horas por semana, lo cual equivaldría a unas 3 horas diarias durante 5 días a la semana.

La naturaleza del proyecto no presenta una complejidad significativa en términos de su alcance y requisitos, lo cual permite abordar su desarrollo a través de un enfoque de ciclo de vida en cascada [20]. No obstante, bajo este enfoque se evita retroceder en cualquiera de las fases del ciclo, y aunque se espera que el diseño y los requisitos del sistema sean estables, existe la posibilidad de realizar ajustes menores conforme se obtenga más información sobre el problema y los métodos. Es por ello que utilizamos una pequeña variante, la versión con retroalimentación.

Las fases del ciclo de vida son:

- **Análisis de requisitos:** Consiste en reuniones iniciales con los clientes, en este caso sería los directores del TFG. Se organiza el análisis bibliográfico del problema *IQA* y *PCQA*⁴, teniendo en cuenta un estudio previo de las distorsiones médicas.
- **Diseño:** Consistió en la investigación y selección de métodos conforme al análisis anterior, tanto para la resolución como la validación de la solución. Así como pruebas preliminares y diseño del software de experimentación.
- **Implementación:** Consiste en la adaptación de las técnicas encontradas, implementación de nuevas funcionalidades y generación de un conjunto de datos médicos nuevos.
- **Pruebas:** Realización de diversos experimentos de validación, tanto al la generación de las distorsiones como a los modelos y resultados.

Tarea	Semanas - Horas	Febrero		Marzo				Abril				Mayo					Junio				Julio			
		21	28	07	14	21	28	04	11	18	25	02	09	16	23	30	06	13	20	27	04	11	18	25
Análisis de Requisitos	4 - 60																							
Diseño	4 - 60																							
Implementación	6 - 90																							
Pruebas	6 - 90																							

Tabla 1.1: Planificación temporal inicial del proyecto

La planificación (1.1) se tomó como referencia, pero no de forma estricta. Ya que se tuvo en cuenta que el autor estaba realizando prácticas de empresa, tenía una asignatura y participaba de un curso de *Google* ofrecido por la universidad. Además, se esperaba que ocurriera retrasos sobre todo en la implementación, como se puede ver en (1.2), dado la novedad de la propuesta y dificultad del problema. Un ejemplo fue a la hora de simular las distorsiones médicas, caso que fue algo iterativo y manual.

Tarea	Semanas - Horas	Febrero		Marzo		Abril				Mayo					Junio				Julio					
		21	28	07	14	21	28	04	11	18	25	02	09	16	23	30	06	13	20	27	04	11	18	25
Análisis de Requisitos	5 - 75																							
Diseño	4 - 60																							
Implementación	8 - 120																							
Pruebas	6 - 90																							

Tabla 1.2: Planificación resultante del proyecto

Para realizar este proyecto se tuvo en cuenta los siguientes materiales: Suscripción a *Google Colab Pro*, un portátil personal de gama media, *Google Drive 100GB* y otros gastos. Además, para el coste estimado, se asume un salario de 25€/hora, como para un investigador *senior* o responsable I+D de una empresa tecnológica en España.

⁴ *Point cloud quality assessment* o estimación de calidad de nubes de puntos

Respecto al servidor GPU, con las especificaciones actuales de *Google*, se estima un coste aproximado de 10.000€. Se asume una amortización de 2 años, lo que implica un pago diario de 13.70€. El desglose total de los costes se puede ver en la siguiente tabla (1.4)

Fecha inicio	21/02/2022
Fecha fin	25/07/2022
Duración	154 días, 110 laborables

Tabla 1.3: Total de horas y días trabajados

Item	Costo
Salario	8 250.00€
Portátil de Gama Media	700.00€
Google Colab Pro	55.50€
Servidor GPU	2 109.8€
Google Drive 100GB	10.00€
Otros	300.00€
Total	11 425.3 €

Tabla 1.4: Estimación final de coste del proyecto

Capítulo 2

Fundamentos Teóricos

Esta sección tiene el objetivo de introducir y explicar brevemente los fundamentos teóricos en los que se basan los métodos empleados en este proyecto, así como justificar su relevancia en la resolución del problema que se plantea.

2.0.1. Subproblemas de la IQA

Existen tres subproblemas presenten en el ámbito de *IQA*. Los primeros, son problemas dónde tenemos acceso a la imagen original, que suponemos exenta de desperfectos, en la cual se pueden aplicar métodos basados en diferencia de características entre ambas, como puede ser al nivel del color de píxel posición a posición, y se denomina “*Full Reference*” (*FR*). La tarea, aparentemente sencilla, en realidad presenta una complejidad alta dada por la necesidad de codificar la percepción humana a la hora de calificar la calidad de una imagen [21]. Ya que métricas que miden distancias no suelen ser suficientes al no haber buena correlación entre la calidad percibida y el resultado de la métrica.

La mayoría de las veces no se menciona, pero al optar métodos de sensibilidad al error (distancias) se imponen un conjunto de suposiciones cuestionables. Primeramente se asume la misma importancia para todas las señales de la imagen, que la magnitud del error es lo único que determina la calidad, que el contenido de la imagen no afecta al resultado final tras aplicar una distorsión y que si cambiamos el orden de las señales la medida de distorsión no es afectada. Lamentablemente, ninguna de estas suposiciones se cumplen [3], ver imágenes (2.1,2.2).

Sección Intro. subproblemas a Fundamentos. IQA

El siguiente subproblema es aquel donde tenemos algún tipo de información adicional respecto a la imagen original en el momento de análisis de la calidad de la imagen final, denominados “*Reduced Reference*” (*RR*). La información extra puede incluir características estadísticas, metadatos, parámetros de

compresión o características extraídas de una región de interés específica.

Y por último, tenemos aquellos problemas donde desconocemos el origen y cualquier información respecto a la imagen inicial, denominados problemas “*No reference*” (*NR*). Estas métricas están exentas de cualquier información de referencia y se centran en capturar características generales de calidad.

La evaluación de calidad de imagen sin referencia es, quizás, el problema más difícil en el análisis de imágenes. De cierto modo, el modelo debe ser capaz de evaluar la calidad cualquier imagen sin saber nada de la imagen “real” original. Superficialmente parece “misión imposible”. No obstante, sorprendentemente esa es una tarea muy sencilla para el ser humano [3].

Para resolverlo, debemos disponer de conocimientos de la naturaleza de las imágenes de las que tratamos y los efectos de las distorsiones. Lo que se denomina estadísticas naturales de escena (NSS, por sus siglas en inglés). Un ejemplo sería JPEG, un algoritmo de compresión que se codifica por bloques 8x8. Los efectos negativos de la compresión se representan por el difuminado entre bloques y los artefactos que presentan. Entender estos efectos permite diseñar métricas específicas [22, 23] As veces resulta difícil describir las características de la imagen y los efectos de la distorsión. Es por ello que los métodos de aprendizaje profundo son cada vez más frecuente y dan mejores resultados. Permitimos que sea la máquina la que aprenda las propiedades de la distorsión, su relación con el contenido y efecto sobre la percepción visual [24–26].

La complejidad del problema crece conforme nos desplazamos a las tres dimensiones. El analizar la calidad de los modelos *3D* implica mayor nivel de dificultad dado que nos enfrentamos a dos grandes retos: La complejidad computacional de las operaciones y la escasez de bases de datos etiquetadas sobre objetos tridimensionales para entrenar y evaluar modelos.

Para las nubes de puntos, que representan una colección de puntos en un espacio tridimensional (x, y, z) cada uno con un color asociado *RGB*, se pueden emplear métricas y algoritmos basándose en criterios como la densidad de puntos, la uniformidad, la precisión geométrica y la detección de artefactos. También se pueden considerar aspectos relacionados con la coherencia de los colores o texturas asociadas a los puntos [27–29]

Un enfoque común es la evaluación de calidad de una nube de puntos tridimensional mediante proyecciones *2D* desde diferentes perspectivas [30–32]. De esta forma podemos tratar el problema como uno de *IQA 2D* reduciendo la complejidad computacional, pudiendo implementar métodos y soluciones ya existentes.

Teniendo en cuenta todas estas consideraciones, el presente TFG aborda la estimación, sin referencia, de calidad de imágenes médicas en espacio

tridimensional.




Figura 2.1: En este ejemplo, extraído de [2], vemos que sumar una constante positiva a una imagen de referencia (a) produce la imagen (b) que contiene la misma distancia *Minkowski*¹ que (c), imagen fabricada por la misma constante pero permutando signo de forma aleatoria. Siendo que la percepción final es que la imagen (c) es peor que la (b).

2.1. Aprendizaje Automático

El aprendizaje automático [33] o *Machine Learning* (*ML*) es una de las ramas que compone lo que definimos como la inteligencia artificial (*IA*). Esta última se puede definir, según [34], como “La ciencia e ingeniería de crear máquinas inteligentes, especialmente programas de computadora inteligentes. Está relacionada con la tarea similar de utilizar computadoras para comprender la inteligencia humana...”

En este caso hablamos de dar soluciones a problemas complejos sin solución analítica (o que resulta muy costoso hallarla), es decir, necesitamos que la computadora sea la que identifique los patrones en los datos y realice predicciones sobre ellos [35]. Se puede definir más formalmente que un programa aprende de la experiencia *E* con respecto a alguna clase de tareas *T* y una métrica de rendimiento *P* si su rendimiento en las tareas *T*, medido con *P*, mejora con la experiencia *E* [36].

Dependiendo de factores como las necesidades del problema, la naturaleza de los datos a utilizar o el objetivo a alcanzar, podemos encontrar distintos

¹La distancia de *Minkowski* es una métrica vectorial que puede considerarse como una generalización tanto de la distancia euclidia como de la distancia de Manhattan .

²*MSE*: *Mean squared error* o error cuadrático medio es una métrica de distancia que se calcula como la media de la suma de las diferencias al cuadrado.

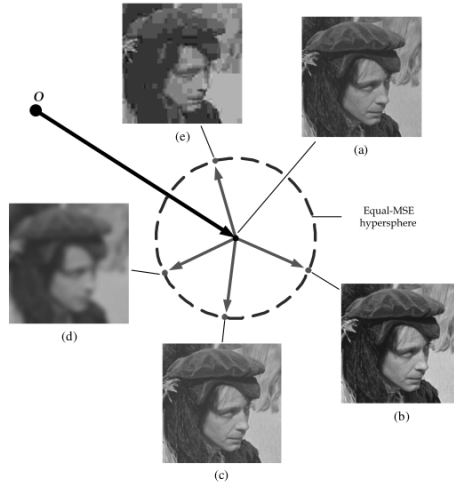


Figura 2.2: En este ejemplo, extraído de [3], la misma imagen distorsionada de distintas maneras resulta en el mismo valor $MSE^2=181$. Siendo evidente que algunas distorsiones producen efectos visuales más marcados que otras haciendo que no sea una buena estimación perceptual de la calidad.

tipos de algoritmos de aprendizaje. En este documento se recogerán dos grandes grupos: aprendizaje supervisado y aprendizaje no supervisado. En el primero disponemos de un conjunto de datos anotados, es decir, con las salidas deseadas para cada ejemplo y en el segundo se espera que sea la máquina la que determine los patrones (2.3).

En general se suelen aplicar las técnicas de *ML* sobre grandes conjuntos de datos sobre los cuales deseamos detectar los patrones subyacentes [37].

Puede observarse que dada estas descripciones, al problema presente podemos aplicarle alguna técnica de *ML*: Tenemos datos de entrada (nubes de puntos distorsionadas) y una salida (valor de calidad). Además, existen conjuntos de datos públicos etiquetadas para distintos tipos de distorsiones. Esto significa que estamos entre un problema de aprendizaje supervisado.

2.2. Aprendizaje Profundo

El aprendizaje profundo o *Deep Learning* (*DL*)

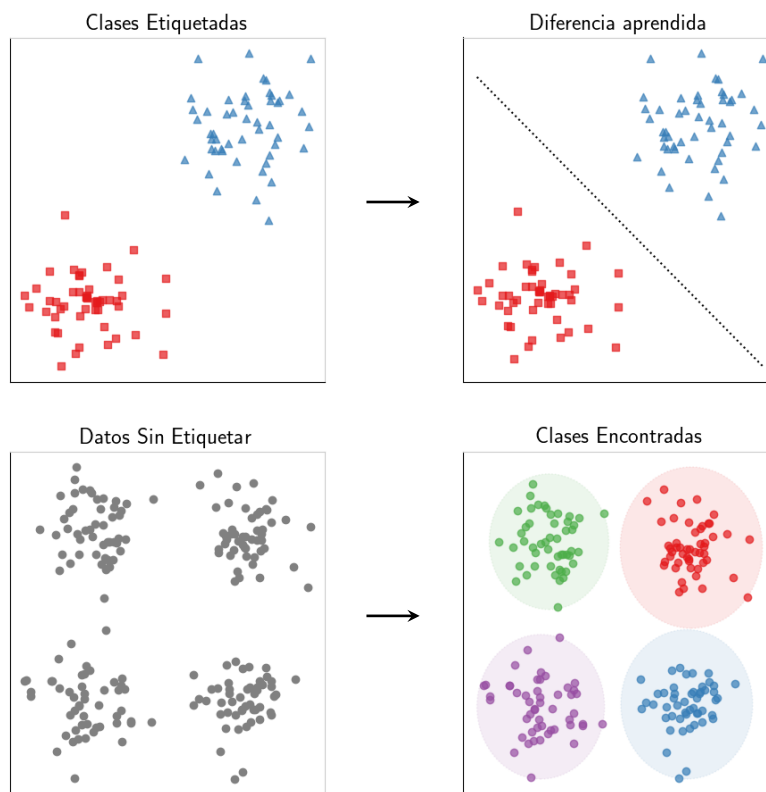


Figura 2.3: Ejemplo de aprendizaje supervisado y no supervisado. En el primer par, vemos como dado un conjunto de clases etiquetadas aprendemos un hiper plano que las separa. En el segundo, dado un conjunto de puntos aprendemos un conjunto de clases.

-
- 2.2.1. Redes Convolucionales
 - 2.2.2. Aplicadas a Videos
 - 2.3. Ensemble o Conjunto *Deep Learning*
 - 2.4. Imágenes médicas, Métricas y Distorsiones

Capítulo 3

Estado del Arte

Capítulo 4

Materiales, Métodos y Distorsiones

4.1. Materiales

4.2. Métodos

4.3. Distorsiones

Capítulo 5

Implementación y Experimentos

5.1. Detalles Técnicos de Implementación

5.2. Experimentos

Capítulo 6

Conclusiones y Trabajos Futuros

Bibliografía

- [1] Andriy Fedorov, Reinhard Beichel, Jayashree Kalpathy-Cramer, Julien Finet, Jean-Christophe Fillion-Robin, Sonia Pujol, Christian Bauer, Dominique Jennings, Fiona Fennessy, Milan Sonka, John Buatti, Stephen Aylward, James V. Miller, Steve Pieper, and Ron Kikinis. 3d slicer as an image computing platform for the quantitative imaging network. *Magnetic Resonance Imaging*, 30(9):1323–1341, 2012. Quantitative Imaging in Cancer. URL: <https://www.sciencedirect.com/science/article/pii/S0730725X12001816>, doi:<https://doi.org/10.1016/j.mri.2012.05.001>.
- [2] Kalpana Seshadrinathan, Thrasyvoulos Pappas, Robert Safranek, Junqing Chen, Zhou Wang, Hamid Sheikh, and Alan Bovik. Image quality assessment. *The Essential Guide to Image Processing*, 12 2009. doi:10.1016/B978-0-12-374457-9.00021-4.
- [3] Zhou Wang and Alan Conrad Bovik. Modern image quality assessment. In *Modern Image Quality Assessment*, 2006.
- [4] Yong Ding. *Visual Quality Assessment for Natural and Medical Image*. 03 2018. doi:10.1007/978-3-662-56497-4.
- [5] Illya Bakurov, Marco Buzzelli, Raimondo Schettini, Mauro Castelli, and Leonardo Vanneschi. Structural similarity index (ssim) revisited: A data-driven approach. *Expert Systems with Applications*, 189:116087, 2022. URL: <https://www.sciencedirect.com/science/article/pii/S0957417421014238>, doi:<https://doi.org/10.1016/j.eswa.2021.116087>.
- [6] Edoardo Ardizzone and Alessandro Bruno. Image quality assessment by saliency maps. volume 1, 02 2012.
- [7] Jinjian Wu, Jupo Ma, Fuhu Liang, Weisheng Dong, Guangming Shi, and Weisi Lin. End-to-end blind image quality prediction with cascaded deep neural network. *IEEE Transactions on Image Processing*, 29:7414–7426, 2020. doi:10.1109/TIP.2020.3002478.

-
- [8] Netflix. Video multi-method assessment fusion. <https://github.com/charlespwd/project-title>, 2016.
 - [9] Reza Rassool. Vmaf reproducibility: Validating a perceptual practical video quality metric. In *2017 IEEE International Symposium on Broadband Multimedia Systems and Broadcasting (BMSB)*, pages 1–2, 2017. doi:10.1109/BMSB.2017.7986143.
 - [10] Zhou Wang. Applications of objective image quality assessment methods [applications corner]. *IEEE Signal Processing Magazine*, 28(6):137–142, 2011. doi:10.1109/MSP.2011.942295.
 - [11] Charles Parisot. The dicom standard. *The International Journal of Cardiac Imaging*, 11(3):171–177, Sep 1995. doi:10.1007/BF01143137.
 - [12] Karl Heinz Höhne, Henry Fuchs, and Stephen M. Pizer. 3d imaging in medicine : algorithms, systems, applications. 1990.
 - [13] Orhan Hakki Karatas and Ebubekir Toy. Three-dimensional imaging techniques: A literature review. *European Journal of Dentistry*, 8:132 – 140, 2014.
 - [14] Luuk H G A Hopman, Pranav Bhagirath, Mark J Mulder, Iris N Eggink, Albert C van Rossum, Cornelis P Allaart, and Marco J W Götte. Quantification of left atrial fibrosis by 3D late gadolinium-enhanced cardiac magnetic resonance imaging in patients with atrial fibrillation: impact of different analysis methods . *European Heart Journal - Cardiovascular Imaging*, 23(9):1182–1190, 11 2021. arXiv:<https://academic.oup.com/ehjcmimaging/article-pdf/23/9/1182/45316536/jeab245.pdf>, doi:10.1093/ehjci/jeab245.
 - [15] Yuhao Sun and Gabriela Mogos. Impact of visual distortion on medical images. *IAENG International Journal of Computer Science*, 49:36–45, 03 2022.
 - [16] Elin Kjelle and Catherine Chilanga. The assessment of image quality and diagnostic value in x-ray images: a survey on radiographers’ reasons for rejecting images. *Insights into Imaging*, 13, 03 2022. doi:10.1186/s13244-022-01169-9.
 - [17] ITU-R. Methodology for the subjective assessment of the quality of television pictures. ITU-R Recommendation BT.500-13, International Telecommunication Union - Radiocommunication Sector (ITU-R), 2012.
 - [18] Junming Zhou, Gangyi Jiang, Xiangying Mao, Mei Yu, Feng Shao, Zongju Peng, and Yun Zhang. Subjective quality analyses of stereoscopic images in 3dtv system. 11 2011. doi:10.1109/VCIP.2011.6115913.

-
- [19] Yipeng Liu, Qi Yang, Yiling Xu, and Le Yang. Point cloud quality assessment: Dataset construction and learning-based no-reference metric. 12 2020. URL: <http://arxiv.org/abs/2012.11895>.
 - [20] R. S. Pressman. *Software Engineering: A Practitioner's Approach*. Palgrave Macmillan, 2005.
 - [21] Zhou Wang, Alan C. Bovik, and Ligang Lu. Why is image quality assessment so difficult? In *2002 IEEE International Conference on Acoustics, Speech, and Signal Processing*, volume 4, pages IV–3313–IV–3316, 2002. doi:10.1109/ICASSP.2002.5745362.
 - [22] Zhou Wang, H.R. Sheikh, and A.C. Bovik. No-reference perceptual quality assessment of jpeg compressed images. In *Proceedings. International Conference on Image Processing*, volume 1, pages I–I, 2002. doi:10.1109/ICIP.2002.1038064.
 - [23] Zhou Wang, A.C. Bovik, and B.L. Evan. Blind measurement of blocking artifacts in images. In *Proceedings 2000 International Conference on Image Processing (Cat. No.00CH37101)*, volume 3, pages 981–984 vol.3, 2000. doi:10.1109/ICIP.2000.899622.
 - [24] Kwan-Yee Lin and Guanxiang Wang. Hallucinated-iqa: No-reference image quality assessment via adversarial learning. URL: <https://kwanyeelin.github.io>.
 - [25] Weixia Zhang, Kede Ma, Jia Yan, Dexiang Deng, and Zhou Wang. Blind image quality assessment using a deep bilinear convolutional neural network. *IEEE Transactions on Circuits and Systems for Video Technology*, 30:36–47, 1 2020. doi:10.1109/TCSVT.2018.2886771.
 - [26] Kede Ma, Wentao Liu, Tongliang Liu, Zhou Wang, and Dacheng Tao. Dipiq: Blind image quality assessment by learning-to-rank discriminable image pairs. *IEEE Transactions on Image Processing*, 26:3951–3964, 8 2017. doi:10.1109/TIP.2017.2708503.
 - [27] Zicheng Zhang, Wei Sun, Xiongkuo Min, Tao Wang, Wei Lu, and Guangtao Zhai. No-reference quality assessment for 3d colored point cloud and mesh models. *IEEE Transactions on Circuits and Systems for Video Technology*, 32(11):7618–7631, 2022. doi:10.1109/TCSVT.2022.3186894.
 - [28] Wei Zhou, Qi Yang, Qiuping Jiang, Guangtao Zhai, and Weisi Lin. Blind quality assessment of 3d dense point clouds with structure guided resampling, 2022. arXiv:2208.14603.

-
- [29] Ziyu Shan, Qi Yang, Rui Ye, Yujie Zhang, Yiling Xu, Xiaozhong Xu, and Shan Liu. Gpa-net:no-reference point cloud quality assessment with multi-task graph convolutional network, 2023. [arXiv:2210.16478](#).
 - [30] Qi Yang, Yipeng Liu, Siheng Chen, Yiling Xu, and Jun Sun. No-reference point cloud quality assessment via domain adaptation, 2022. [arXiv:2112.02851](#).
 - [31] Zicheng Zhang, Wei Sun, Yucheng Zhu, Xiongkuo Min, Wei Wu, Ying Chen, and Guangtao Zhai. Treating point cloud as moving camera videos: A no-reference quality assessment metric, 2022. [arXiv:2208.14085](#).
 - [32] Zicheng Zhang, Wei Sun, Xiongkuo Min, Quan Zhou, Jun He, Qiyuan Wang, and Guangtao Zhai. Mm-pcqa: Multi-modal learning for no-reference point cloud quality assessment. 09 2022. [doi:10.48550/arXiv.2209.00244](#).
 - [33] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 3 edition, 2010.
 - [34] John McCarthy. What is artificial intelligence? 01 2004.
 - [35] Yaser S. Abu-Mostafa, Malik Magdon-Ismael, and Hsuan-Tien Lin. *Learning From Data*. AMLBook, 2012.
 - [36] Tom M. Mitchell. Machine learning. In *Machine Learning*, chapter 1, page 2. McGraw-Hill, 1997.
 - [37] Oded Maimon and Lior Rokach, editors. *Data mining and knowledge discovery handbook*. Springer Science+Business Media, LLC, Boston, MA, 2 edition, 2010. URL: <https://doi.org/10.1007/978-0-387-09823-4>.
 - [38] 3D Slicer image computing plataform. <https://www.slicer.org/>. Visualizada en: 2023-06-01.